

UNIVERSIDAD DE GUADALAJARA

ARQUITECTURA DE SISTEMAS DE INTELIGENCIA ARTIFICIAL

CUGDL

Prerrequisitos
ASIA:
Machine Learning I

Mtro. David Echavarry

10 de marzo de 2026

Agenda

- Objetivo de clase
 - ¿Qué es Machine Learning?
 - Componentes de un agente
 - Componentes de un modelo de aprendizaje
 - Modelos de ML como Funciones Input→Output
 - Tipos de salidas en ML
 - Tipos de aprendizaje en ML
 - Formas de aprendizaje
 - Sesgo, varianza y complejidad
 - Tipos de conjuntos de datos

Objetivo

Idea clave

- Dotar al alumno con los **conceptos básicos y fundamentos de Machine Learning** para un curso de ASIA.

¿Qué es Machine Learning?

Aprendizaje de máquina

- **Machine Learning** es la capacidad de una computadora para aprender.
- **Machine Learning** es el proceso mediante el cual un agente o modelo **modifica y mejora sus componentes a partir de experiencia**, con el objetivo de optimizar su desempeño respecto a una medida de rendimiento.

Componentes de un Agente y Aprendizaje

Componentes de un Agente

■ ¿Qué es un componente de un agente?

Un componente de un agente es una parte funcional interna que permite percibir, procesar información y actuar sobre el entorno, contribuyendo al comportamiento global del sistema.


■ Componentes fundamentales de todo agente:

- Sensores (percibir el entorno)
- Actuadores (actuar sobre el entorno)
- Programa del agente (decidir acciones a partir de perceptos)
- Entorno con el que interactúa

■ ¿Qué es aprender?

Aprender es el proceso mediante el cual **el agente modifica y mejora sus componentes internos** (especialmente su programa de decisión) a partir de la experiencia y retroalimentación (feedback), con el objetivo de mejorar su desempeño en el entorno.

Componentes de un Agente



Visualización de partes de un agente

Componentes de un Modelo de Aprendizaje

Componentes de un Modelo de Machine Learning

■ ¿Qué es un modelo de aprendizaje?

Es una estructura computacional diseñada para aproximar una función a partir de datos.


■ Componentes fundamentales de todo modelo de ML:

- Hipótesis
- Espacio de hipótesis (conjunto de funciones posibles)
- Parámetros ajustables
- Función de pérdida (criterio de evaluación)
- *Algoritmo de optimización/aprendizaje (mecanismo de ajuste)
- Datos o experiencia

■ ¿Qué es aprender en un modelo de ML?

Aprender es el proceso mediante el cual un **modelo ajusta sus parámetros a partir de datos de entrenamiento** para aproximar una función que relacione entradas con salidas, con el objetivo de **minimizar el error y generalizar a datos no vistos**.

Componentes de un modelo de aprendizaje



Modelos de ML como Funciones Input→Output

Definición de modelo

Todo modelo de Machine Learning **implementa una función** $f(x)$ que transforma datos de entrada X en algún tipo de salida Y , ya sea una **predicción**, una **decisión**, una **representación** o una **estructura**.

$$f : X \longrightarrow Y$$

Modelos de ML como Funciones Input→Output



Visualización de un modelo de ML

Tipos de Output en ML

Clasificación

La salida del modelo pertenece a un conjunto discreto de **categorías o clases**. Pueden ser multi-clase no solamente binarias.

$$f : X \rightarrow \{c_1, c_2, \dots, c_k\}$$

Ejemplos de salidas categóricas (discretas):

- Spam / No Spam
- Perro / Gato
- Aprobado / Reprobado
- Etc...

Las salidas son **variables cualitativas**.

Tipos de Output en ML

Regresión

La salida del modelo es un valor continuo dentro de un intervalo **numérico**.

$$f : X \rightarrow \mathbb{R}$$

Ejemplos de salidas numéricas (continuas):

- Precio de una casa
- Temperatura
- Probabilidad estimada
- Etc..

Las salidas son **variables cuantitativas**.

Tipos de Aprendizaje en Machine Learning

Aprendizaje Supervisado

■ ¿Cómo aprende?

Aprende a partir de ejemplos donde **ya conocemos la respuesta correcta** y lo vamos "guiando" para reajustar sus parametros.

■ ¿Cuándo se usa?

Cuando queremos predecir algo categórico: clasificar correos como spam, predecir precios, diagnosticar enfermedades, reconocer imágenes, etc.

- **NOSOTROS SOMOS EL SUPERVISOR** de la salida del modelo.

■ Ejemplos:

- Detección de spam
- Predicción del precio de una casa
- Clasificación de imágenes (perro/gato)
- Diagnóstico médico

■ Modelo:

Datos: (x, y)

Función aprendida:

$$f : X \rightarrow Y$$

Salida: predicción $\hat{y}$.

Tipos de Aprendizaje en Machine Learning

Aprendizaje No Supervisado

■ ¿Cómo aprende?

Aprende buscando patrones o estructura en los datos sin conocer respuestas previas, esto es, **cundo no conocemos las posibles salidas**.

■ ¿Cuándo se usa?

Cuando queremos descubrir agrupaciones, reducir dimensiones, detectar anomalías o encontrar estructura oculta en los datos.

■ Ejemplos:

- Segmentación de clientes
- Clustering de documentos
- Reducción de dimensiones (PCA)
- Detección de anomalías

■ Modelo:

Datos: x

Función aprendida:

$$f : X \rightarrow Z$$

Salida: estructura, representación o agrupación Z .

Tipos de Aprendizaje en Machine Learning

Aprendizaje por Refuerzo

■ ¿Cómo aprende?

Aprende interactuando con el entorno, **recibiendo recompensas o penalizaciones** según las acciones que toma.

■ ¿Cuándo se usa?

Cuando el problema implica toma de decisiones secuenciales: juegos, robótica, control automático, sistemas autónomos.

■ Ejemplos:

- Agentes que juegan ajedrez o videojuegos
- Robots autónomos
- Control de tráfico
- Sistemas de recomendación adaptativos

■ Modelo:

Entrada: estado s

Función aprendida:

$$\pi : S \rightarrow A$$

Salida: acción A que maximiza recompensa acumulada.

Formas de aprendizaje

Función de hipótesis (Hypothesis Function)

- La función h se denomina **hipótesis (hypothesis)**

$$h(x)$$

y representa **un modelo posible de los datos.**

- Dicha hipótesis es seleccionada de un conjunto de funciones posibles llamado **espacio de hipótesis (hypothesis space)**:

$$H = \{h_1, h_2, \dots, h_n\}$$

donde cada $h_i \in H$

- El aprendizaje consiste en **elegir la mejor hipótesis dentro de H que aproxime a la función verdadera $f(x)$.**

Formas de aprendizaje

Verdad fundamental (Ground Truth)

- La **verdad fundamental (ground truth)** es la respuesta real que queremos que el modelo aprenda a predecir.

$$y_i = f(x_i)$$

- Es el valor verdadero generado por la función desconocida f .
- **Ejemplo:**
 - Si queremos predecir el precio de una casa, el precio real es el ground truth.
 - En clasificación de imágenes, la etiqueta correcta (perro/gato) es el ground truth.

Formas de aprendizaje

Elección del espacio de hipótesis H (Choosing Hypothesis Space H)

- Elegimos un conjunto de funciones posibles H basado en:
 - Conocimiento previo (prior knowledge)
 - Análisis exploratorio de datos (exploratory data analysis)
- Buscamos una hipótesis $h \in H$ tal que:

$$h(x_i) \approx y_i$$

- Es decir, tratamos de encontrar la función que mejor se ajuste a los datos observados.
- **Ejemplo:**
 - Si creemos que la relación es lineal, elegimos funciones lineales.
 - Si sospechamos patrones complejos, elegimos redes neuronales o árboles.

Formas de aprendizaje

Ejemplo de Espacio de Hipótesis




Supongamos un conjunto de datos donde:

x : tamaño de la vivienda

y : precio de la vivienda

Queremos encontrar una función $h(x)$ que aproxime la función verdadera $f(x)$.

Distintos espacios de hipótesis posibles:




El aprendizaje consiste en seleccionar la hipótesis $h(x)$ dentro del espacio H que mejor aproxime la función verdadera $f(x)$.

Formas de aprendizaje

Elección del Espacio de Hipótesis H (Choosing Hypothesis Space)

Ejemplo: Si creemos que la relación es lineal, elegimos funciones lineales.

Si sospechamos patrones complejos, elegimos redes neuronales o árboles.



Formas de aprendizaje

Ajuste del modelo y complejidad

■ Definiciones

- **Underfitting:** ocurre cuando el modelo es demasiado simple y no logra capturar los patrones presentes en los datos, produciendo un alto error tanto en entrenamiento como en datos nuevos.
- **Overfitting:** ocurre cuando el modelo se ajusta demasiado a los datos de entrenamiento, capturando incluso el ruido, lo que produce buen desempeño en entrenamiento pero mala generalización.

■ Relación con la hipótesis y el espacio de hipótesis


- El modelo seleccionado corresponde a una hipótesis $h(x)$ dentro del espacio de hipótesis H .
- **Underfitting:** el espacio de hipótesis es demasiado limitado o la hipótesis elegida es demasiado simple para aproximar la función verdadera $f(x)$.
- **Overfitting:** el espacio de hipótesis es demasiado complejo y permite elegir hipótesis que se ajustan excesivamente a los datos de entrenamiento.

Formas de aprendizaje

Underfitting y Overfitting

Underfitting

Hipótesis demasiado simple




⚠ Alta sesgo, baja varianza, mal desempeño y generalización

⚠ Una hipótesis demasiado simple no capta los patrones en los datos

Overfitting

Overfitting: Hipótesis demasiado compleja



⚠ Bajo sesgo, alta varianza, predicción perfecta en entrenamiento pero mala generalización

⚠ Una hipótesis demasiado compleja memoriza los datos pero no generaliza

Formas de aprendizaje

Generalización vs. Memorización

- No evaluamos el modelo solo por qué tan bien ajusta el conjunto de entrenamiento, sino por su **capacidad de generalizar** a datos no vistos.

Entrenamiento $\neq$ Generalización

- Medimos el desempeño en un **conjunto de prueba (test set)** para verificar que el modelo funcione en nuevos ejemplos.
- **Ejemplo:**
 - Un modelo que memoriza datos de entrenamiento puede fallar con datos nuevos.
 - Un buen modelo mantiene buen desempeño fuera de la muestra.

Sesgo, Varianza y Complejidad


Sesgo (Bias)

- El **sesgo (bias)** es la tendencia de una hipótesis predictiva a desviarse sistemáticamente del valor esperado cuando se entrena con diferentes conjuntos de datos.
- Generalmente surge por restricciones impuestas por el espacio de hipótesis H .
Ejemplo: Un modelo lineal intentando ajustar datos claramente no lineales.

Formas de aprendizaje

Sesgo (bias): tendencia sistemática de una hipótesis

El sesgo es la tendencia de una hipótesis predictiva a desviarse sistemáticamente del valor esperado cuando se entrena con diferentes conjuntos de datos.



La hipótesis se desvía sistemáticamente del verdadero $f(x)$ al entrenarse con diferentes conjuntos de datos.

Sesgo, Varianza y complejidad

Varianza (Variance)

La **varianza (variance)** mide cuánto cambia la hipótesis aprendida cuando cambia el conjunto de entrenamiento.

Alta varianza implica:

- Sensibilidad excesiva a pequeñas variaciones en los datos.
- Inestabilidad en las predicciones.


Formas de aprendizaje

Varianza (Variance)

La varianza (variance) mide cuánto cambia la hipótesis aprendida cuando cambia el conjunto de entrenamiento.

Alta varianza implica:

- Sensibilidad excesiva a pequeñas variaciones en los datos.
- Inestabilidad en las predicciones



Alta Varianza (High Variance)

Sesgo, varianza y complejidad

Compromiso Sesgo–Varianza (Bias–Variance Tradeoff)

- Existe un equilibrio entre:
 - Hipótesis de bajo sesgo (más expresivas, más complejas).
 - Hipótesis de baja varianza (más simples, más estables).
 - Esto es,
 - Bias baja $\rightarrow$ Varianza alta
 - Varianza baja $\rightarrow$ Bias alta
- Elegimos la hipótesis h que tenga mayor probabilidad de ser verdadera después de observar los datos:


$$h^* = \arg \max_{h \in H} P(h \mid \text{data}).$$

por Bayes esto es equivalente a

$$h^* = \arg \max_{h \in H} P(\text{data} \mid h)P(h).$$

- Esto conduce al **compromiso expresividad–complejidad** (**expressiveness–complexity tradeoff**):
modelos más expresivos pueden ajustarse mejor, pero también pueden sobreajustar.

Formas de aprendizaje



Tipos de conjuntos de datos (Types of Sets)

I. Conjunto de entrenamiento (Training Set)

- Es el conjunto de datos utilizado para que **el modelo aprenda**.
- Durante esta fase, el modelo **ajusta sus parámetros** internos con el objetivo de aproximar la función verdadera.
- **Aquí ocurre el proceso de aprendizaje propiamente dicho.**
- **Ejemplo:** Si tenemos 10,000 imágenes, una parte se usa para que el modelo aprenda a reconocer patrones.

Tipos de conjuntos de datos (Types of Sets)

II. Conjunto de validación (Validation Set)

- Es el conjunto utilizado para **ajustar los hiperparámetros** del modelo y seleccionar la mejor configuración.
- No modifica directamente los parámetros internos del modelo, sino que permite elegir:
 - Complejidad del modelo
 - Profundidad de un árbol
 - Número de vecinos
 - Tasa de aprendizaje
- **Ayuda a prevenir el sobreajuste.**
- **Ejemplo:** En una red neuronal, el conjunto de validación se utiliza para comparar distintas configuraciones de hiperparámetros, como la tasa de aprendizaje ($\eta = 0,001, 0,01, 0,1$), el número de capas ocultas o el tamaño del batch, seleccionando la combinación que produce el mejor desempeño en los datos de validación.


Tipos de conjuntos de datos (Types of Sets)

III. Conjunto de prueba (Test Set)

- Es el conjunto reservado **exclusivamente** para la evaluación final del modelo.
- Aquí **verificamos si el modelo generaliza correctamente** a datos nuevos y no vistos durante el entrenamiento ni la validación.
- Su propósito es medir el **desempeño real** esperado en el mundo.
- **Clave:** El conjunto de prueba no debe utilizarse para ajustar el modelo.
- **Ejemplo:** Tras entrenar y ajustar el modelo, se evalúa en el conjunto de prueba con datos nunca vistos para medir su desempeño real (por ejemplo, exactitud o precisión).

Tipos de conjuntos de datos (Types of Sets)

Tipos de Conjuntos de Datos



Bibliografía

Referencias

- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.