

UNIVERSIDAD DE GUADALAJARA

ARQUITECTURA DE SISTEMAS DE INTELIGENCIA ARTIFICIAL

Pipelines

Mtro. David Echavarry

16 de abril de 2026

Agenda

Temas

- Objetivo
- Fundamentos de pipelines de IA
- Componentes de un pipeline de IA
- Tipos de pipelines
- Patrones de diseño de pipelines
- Pipelines de entrenamiento vs inferencia
- Pipeline de RAG
- Pipeline de fine-tuning
- Pipeline de sistemas de recomendación
- Evaluación en pipelines de IA
- Orquestación de pipelines
- Monitoreo y mantenimiento
- Desafíos en el diseño de pipelines
- Principios de diseño de pipelines
- Metodología para diseñar pipelines
- Actividad práctica

Objetivo

Idea clave

- Comprender que un **pipeline de IA** es un sistema completo y no solamente un modelo aislado.
- Entender que un pipeline organiza el flujo desde los datos de entrada hasta la salida o decisión final.
- Analizar cómo se integran datos, transformaciones, modelos, evaluación y despliegue dentro de un mismo sistema.
- Diseñar pipelines de IA con visión arquitectónica, considerando calidad, escalabilidad, monitoreo y operación real.

Fundamentos de pipelines de IA

Definición de pipeline

- Un pipeline de IA es una secuencia organizada de etapas que transforma datos en predicciones, recomendaciones, decisiones o contenido.
- Un pipeline conecta múltiples componentes que trabajan de forma coordinada.
- Flujo general:
 - Entrada de datos
 - Transformación
 - Representación
 - Modelo
 - Salida
- Idea clave: el valor del sistema no está solo en el modelo, sino en la integración de todas sus etapas.

Fundamentos de pipelines de IA

Rol del pipeline en AI Engineering

- Un pipeline permite pasar de un experimento aislado a un sistema desplegable.
- Integra componentes de IA y no-IA dentro de una misma arquitectura.
- Permite automatizar procesos repetitivos del sistema.
- Facilita la reproducibilidad, el mantenimiento y la evolución del sistema.
- Es fundamental en sistemas modernos como:
 - RAG
 - Fine-tuning
 - Sistemas de recomendación
 - Visión por computadora
 - NLP

Componentes de un pipeline de IA

Etapas fundamentales

- Todo pipeline de IA suele componerse de:
 - Ingesta de datos
 - Preprocesamiento
 - Representación de datos
 - Modelo
 - Postprocesamiento
 - Salida o acción
- Cada etapa cumple una función específica dentro del sistema.
- La separación en componentes mejora el mantenimiento y la escalabilidad.

Componentes de un pipeline de IA




Figura: Ciclo de vida

Componentes de un pipeline de IA

Ingesta y preprocesamiento

- La ingesta de datos consiste en obtener información desde diferentes fuentes.
- Ejemplos de fuentes:
 - APIs
 - Bases de datos
 - Archivos
 - Sensores
 - Streaming
- El preprocesamiento limpia y transforma los datos antes de usarlos.
- Tareas comunes:
 - Eliminar errores
 - Normalizar
 - Filtrar
 - Codificar variables

Componentes de un pipeline de IA

Representación, modelo y salida

- La representación transforma los datos en una forma adecuada para el modelo.
- Ejemplos:
 - Features numéricas
 - Tokenización
 - Embeddings
- El modelo constituye el núcleo de inteligencia del pipeline.
- El postprocesamiento ajusta o refina la salida del modelo.
- La salida puede convertirse en:
 - Respuesta a usuario
 - Recomendación
 - Alerta
 - Acción automatizada

Tipos de pipelines

Clasificaciones principales

- Los pipelines pueden clasificarse según cómo y cuándo procesan la información.
- Tipos comunes:
 - Batch
 - Real-time
 - Offline
 - Online
 - Híbridos
- Cada tipo responde a necesidades distintas de negocio y arquitectura.

Tipos de pipelines

Batch, real-time, offline y online

- Pipeline batch:
 - Procesa grandes volúmenes en intervalos definidos.
 - Es común en entrenamiento y análisis histórico.
- Pipeline real-time:
 - Procesa datos en el momento en que llegan.
 - Se usa en chatbots, recomendación y detección de fraude.
- Pipeline offline:
 - Se enfoca en tareas previas al uso del sistema en producción.
- Pipeline online:
 - Se enfoca en servir predicciones o respuestas en producción.

Patrones de diseño de pipelines

Estructuras comunes

- Existen patrones recurrentes en la forma de organizar un pipeline.
- Los patrones más comunes son:
 - Pipeline lineal
 - Pipeline con branching
 - Pipeline con feedback loop
 - Pipeline modular
- Conocer estos patrones permite diseñar sistemas más claros y reutilizables.

Patrones de diseño de pipelines

Descripción de patrones

- Pipeline lineal:
 - Sigue una secuencia fija de pasos.
- Pipeline con branching:
 - Toma rutas distintas según condiciones o tipos de entrada.
- Pipeline con feedback loop:
 - Reutiliza información generada por el sistema para mejorar etapas futuras.
- Pipeline modular:
 - Divide el sistema en componentes desacoplados.
- Idea clave: los pipelines reales suelen combinar varios de estos patrones.

Pipelines de entrenamiento vs inferencia

Dos grandes categorías

- En sistemas de IA es fundamental distinguir entre:
 - Pipeline de entrenamiento
 - Pipeline de inferencia
- Ambos forman parte del mismo sistema, pero cumplen funciones distintas.
- El primero construye el modelo.
- El segundo utiliza el modelo para producir salidas.

Pipelines de entrenamiento vs inferencia

Diferencias clave

- Pipeline de entrenamiento:
 - Usa datos históricos
 - Incluye preparación, entrenamiento y validación
 - Produce un modelo listo para desplegarse
- Pipeline de inferencia:
 - Usa entradas nuevas en producción
 - Requiere baja latencia
 - Produce predicciones o respuestas
- Idea clave: entrenar y servir un modelo son procesos distintos y deben diseñarse por separado.

Pipeline de RAG

Retrieval-Augmented Generation

- RAG combina recuperación de información con generación de texto.
- Su objetivo es complementar a un modelo generativo con conocimiento externo relevante.
- Es uno de los pipelines más importantes en sistemas modernos basados en LLMs.

Fase offline

- Recolección de documentos
- Chunking
- Generación de embeddings
- Almacenamiento en base vectorial

Pipeline de RAG

Fase online

- El usuario envía una consulta.
- La consulta se convierte en embedding.
- Se recuperan los fragmentos más relevantes.
- El contexto recuperado se integra al prompt.
- El LLM genera una respuesta condicionada por ese contexto.

Idea clave

- RAG no cambia el modelo base; cambia el contexto que recibe.

Pipeline de fine-tuning

Idea general

- Fine-tuning consiste en adaptar un modelo preentrenado a una tarea o dominio específico.
- Requiere un pipeline de datos y evaluación bien definido.
- Es útil cuando se desea especialización del comportamiento del modelo.

Pipeline de fine-tuning

Etapas principales

- Recolección del dataset
- Limpieza y curación de datos
- Formato del dataset para entrenamiento
- Ajuste del modelo
- Evaluación del modelo ajustado
- Liberación y despliegue

Idea clave

- En fine-tuning, la calidad del dataset es determinante para la calidad del resultado final.

Pipeline de sistemas de recomendación

Idea general

- Un sistema de recomendación busca predecir qué contenido, producto o elemento será relevante para un usuario.
- Su pipeline integra datos de usuarios, productos e interacciones.

Etapas principales

- Recolección de interacciones del usuario
- Construcción de perfiles o representaciones
- Modelado de preferencias
- Ranking de opciones
- Presentación de recomendaciones

Otros casos de pipelines

Aplicaciones adicionales

- Los pipelines de IA también aparecen en:
 - Detección de fraude
 - Predicción de demanda
 - Visión por computadora
 - Clasificación automática
 - Sistemas de monitoreo inteligente
- Aunque cambie el dominio, la lógica estructural del pipeline se mantiene.
- Idea clave: aprender a diseñar pipelines permite transferir conocimiento entre distintos problemas.

Evaluación en pipelines de IA

La evaluación como parte del pipeline

- La evaluación no es una actividad separada, sino una parte central del pipeline.
- Permite verificar si el sistema cumple objetivos técnicos y de negocio.
- Puede realizarse en modo offline o online.

Evaluación en pipelines de IA

Evaluación offline y online

- Evaluación offline:
 - Accuracy
 - Precision
 - Recall
 - Loss
- Evaluación online:
 - CTR
 - Engagement
 - Conversión
 - Satisfacción del usuario
- También pueden utilizarse experimentos A/B.
- Idea clave: un pipeline útil no solo funciona técnicamente, sino que también genera valor.

Orquestación de pipelines

Concepto de orquestación

- Orquestar un pipeline significa coordinar y automatizar sus tareas.
- Permite definir dependencias, tiempos de ejecución y control de errores.
- Es fundamental cuando el sistema tiene múltiples etapas o procesos periódicos.

Orquestación de pipelines

Herramientas comunes

- Algunas herramientas usadas en la industria son:
 - Apache Airflow
 - Kubeflow
 - MLflow
 - LangChain
- Estas herramientas ayudan a:
 - Automatizar flujos
 - Programar tareas
 - Registrar experimentos
 - Coordinar componentes

Orquestación de pipelines




Figura: Ciclo de vida con herramientas

Monitoreo y mantenimiento

Operación del pipeline

- Cuando el pipeline se despliega, entra en fase de operación.
- Debe monitorearse continuamente para asegurar su funcionamiento.
- Elementos comunes de monitoreo:
 - Logs
 - Métricas
 - Eventos
 - Trazas
- El monitoreo debe diseñarse desde la arquitectura del sistema.

Monitoreo y mantenimiento

Problemas y mantenimiento

- En producción pueden surgir problemas como:
 - Data drift
 - Model drift
 - Degradación del rendimiento
 - Fallas de integración
- El mantenimiento puede implicar:
 - Reentrenamiento
 - Ajuste de umbrales
 - Cambio de componentes
 - Actualización del pipeline
- Idea clave: desplegar no es el final, sino el inicio de la vida real del sistema.

Desafíos en el diseño de pipelines

Problemas comunes

- Diseñar pipelines reales implica enfrentar múltiples desafíos.
- Algunos de los más importantes son:
 - Calidad de datos
 - Latencia
 - Costos computacionales
 - Escalabilidad
 - Dependencias entre componentes
- Estos desafíos obligan a tomar decisiones arquitectónicas y de negocio.

Principios de diseño de pipelines

Ideas clave

- Un buen pipeline debe diseñarse con principios sólidos de ingeniería.
- Principios importantes:
 - Separación de responsabilidades
 - Idempotencia
 - Reproducibilidad
 - Escalabilidad
 - Observabilidad
- Estos principios permiten que el sistema sea más robusto, mantenible y profesional.

Metodología para diseñar pipelines

Diseño desde cero

- Para diseñar un pipeline de IA es útil seguir una metodología estructurada.
- Pasos recomendados:
 - Definir el problema
 - Identificar las entradas
 - Diseñar las transformaciones
 - Elegir la representación de datos
 - Seleccionar el modelo
 - Definir la salida esperada
 - Establecer métricas
 - Planear despliegue y monitoreo

Metodología para diseñar pipelines




Figura: Ejemplo de metodología

Metodología para diseñar pipelines

Preguntas guía

- ¿Cuál es el input del sistema?
- ¿Qué transformaciones necesita?
- ¿Qué representación usaré?
- ¿Qué modelo o modelos utilizaré?
- ¿Cuál será la salida del sistema?
- ¿Qué nivel de latencia necesito?
- ¿Cómo mediré si funciona bien?
- ¿Cómo lo voy a operar y mantener?

Actividad práctica

Diseño de un pipeline de IA

- Seleccionar un problema real.
- Diseñar el pipeline completo del sistema.
- Representar visualmente sus etapas.
- Justificar las decisiones tomadas.
- Explicar:
 - Entradas
 - Transformaciones
 - Modelo
 - Salida
 - Evaluación
 - Despliegue
 - Monitoreo

Bibliografía

Referencia base

- Bass, L., Lu, Q., Weber, I., & Zhu, L. (2025). *Engineering AI Systems: Architecture and DevOps Essentials*. Addison-Wesley.

Complementaria

- Bass, L., Clements, P., & Kazman, R. *Software Architecture in Practice*.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*.
- Raschka, S. *Build a Large Language Model (From Scratch)*.