Tarea 2 Unidad 1: Ejercicios de Machine Learning

Materia: Arquitecturas de Sistemas de Inteligencia Artificial

Profesor: Mtro. David Echavarry

Alumno: Alan Josue Solano Perez

Ejercicio 1: El concepto de error: de f(x) a L(y,y^)

1) Investigación

En el aprendizaje automático, un modelo implementa una función matemática f:X→Y. Para evaluar qué tan buena es nuestra predicción y^ comparada con la verdad fundamental yi, utilizamos distintos conceptos:

- **Función de pérdida L(y,y^):** Es la brújula matemática del algoritmo. Es una fórmula que calcula el "castigo" que recibe el modelo por cada predicción incorrecta durante el entrenamiento. El objetivo del modelo es minimizar este valor numérico.
- **Error:** Es la equivocación individual; la diferencia exacta entre lo que el modelo predijo para una sola observación y el valor real.
- **Pérdida (Loss):** Es la agregación o promedio de esos errores individuales sobre un conjunto de datos. Es el valor que el optimizador intenta reducir matemáticamente.
- **Desempeño (Performance):** Es qué tan bien resuelve el modelo el problema en el mundo real, medido con métricas comprensibles para el negocio (ej. porcentaje de aciertos).

Ejemplos de pérdidas típicas:

- **Regresión:** Error Cuadrático Medio (MSE), basado en la diferencia (y−y^) elevada al cuadrado para castigar errores grandes.
- **Clasificación:** Entropía Cruzada (Cross-Entropy), basada en probabilidades. Mide qué tan lejos está la probabilidad predicha de la clase real (0 o 1).

2) Razonamiento

1. **Diferente generalización:** Si dos modelos tienen la misma pérdida en entrenamiento, pero diferente pérdida en prueba, significa que el modelo con peor resultado en prueba simplemente "memorizó" los datos de entrenamiento (hizo trampa) en lugar de aprender los patrones subyacentes. A esto se le llama sobreajuste u *overfitting*.
2. **Entrenar vs. Evaluar:** Entrenar implica minimizar una pérdida L porque los algoritmos (como el Descenso del Gradiente) necesitan funciones matemáticas "suaves" y derivables. Sin embargo, evaluar usa métricas distintas (como *Accuracy*) porque a los humanos y al negocio les interesan resultados interpretables, no números abstractos de cálculo diferencial.
3. ¿Qué significa h(xi)≈yi?: En lenguaje natural significa: *"La predicción que arroja nuestra hipótesis (el modelo) para un dato específico es extremadamente cercana o casi idéntica a la realidad de ese dato"*.

Ejercicio 2: Pérdida vs Métrica: ¿qué se optimiza y qué se reporta?

1) Investigación

La idea fundamental es distinguir que la optimización (entrenamiento) no es lo mismo que la evaluación.

- Función de pérdida L(y,y^): Es la métrica interna y técnica que usa la computadora para ajustar sus parámetros. *Ejemplo:* Log-Loss (Entropía Cruzada).
- Métrica de evaluación M(y,y^): Es el indicador externo y de negocio que usamos los humanos para decidir si el modelo es útil. *Ejemplo:* F1-Score.

Razones para separarlas:

1. *Requisito matemático:* La pérdida debe ser continua y derivable para que el modelo aprenda. Las métricas (como contar aciertos) a menudo son escalonadas y no derivables.
2. *Contexto de negocio:* La pérdida trata a todos los errores por igual matemáticamente, pero el negocio puede considerar que un tipo de error es mucho más costoso que otro.

2) Razonamiento

1. Mala métrica con baja pérdida: En clasificación, el modelo puede dar probabilidades bajas pero seguras (ej. predecir 0.49). Su pérdida matemática será baja, pero si el punto de corte (*threshold*) para la métrica es 0.50, fallará en la clasificación final (métrica pobre).
2. Ejemplo real: En **detección de fraudes bancarios**, tener un *accuracy* (exactitud) alto no sirve si el 99% de las transacciones son legítimas (el modelo podría decir "todo es legítimo" y tener 99% de accuracy). Aquí, la métrica correcta es el *Recall* (sensibilidad): preferimos falsas alarmas antes que dejar pasar un fraude real.
3. Error conceptual: Si eliges la métrica equivocada, cometes el error de optimizar un número que no está alineado con el valor real del producto. Crees que estás mejorando el desempeño, pero en realidad estás creando un modelo inútil para el usuario final.

Ejercicio 3: Métricas en aprendizaje supervisado

1) Investigación

Clasificación ($f:X \rightarrow \{c1,...,ck\}$)

- Accuracy (Exactitud):
  - *Definición:* Porcentaje total de predicciones correctas sobre el total de casos.
  - *Interpretación:* Alto (cercano a 1) es bueno en datos equilibrados; Bajo significa que el modelo falla mucho.
  - *Contexto:* Reconocimiento de imágenes donde todas las clases importan igual (perros vs. gatos).
- Precision (Precisión):
  - *Definición:* De todos los que el modelo predijo como "Positivos", cuántos realmente lo eran.
  - *Interpretación:* Alto significa pocas falsas alarmas.
  - *Contexto:* Filtros de Spam (no queremos que un correo importante se marque como spam).
- Recall (Sensibilidad):
  - *Definición:* De todos los "Positivos" reales en el dataset, cuántos logró encontrar el modelo.
  - *Interpretación:* Alto significa que no se escapan los casos importantes.
  - *Contexto:* Detección de cáncer.
- F1-score:
  - *Definición:* La media armónica entre Precision y Recall. Busca un equilibrio entre ambas.
  - *Interpretación:* Alto significa un modelo robusto que no sacrifica precisión por sensibilidad.
  - *Contexto:* Datasets muy desbalanceados donde importan tanto los falsos positivos como negativos.
- ROC-AUC:
  - *Definición:* Mide la capacidad del modelo para distinguir entre clases variando su umbral de decisión.
  - *Interpretación:* 1.0 es perfecto, 0.5 es igual a lanzar una moneda al azar.
  - *Contexto:* Comparación general de modelos médicos o de crédito antes de fijar un umbral operativo.

Regresión ($f:X \rightarrow R$)

- MAE (Error Absoluto Medio):
  - *Definición:* Promedio de las diferencias absolutas entre predicción y realidad.

    - *Interpretación:* Bajo es mejor. Se interpreta en la misma unidad que los datos originales.
    - *Contexto:* Predicción de precios de casas de forma lineal.
- MSE (Error Cuadrático Medio):
    - *Definición:* Promedio de las diferencias elevadas al cuadrado.
    - *Interpretación:* Bajo es mejor. Al elevar al cuadrado, castiga severamente los errores grandes.
    - *Contexto:* Algoritmos internos de optimización matemáticamente amigables.
- RMSE (Raíz del Error Cuadrático Medio):
    - *Definición:* La raíz cuadrada del MSE, devolviendo el error a sus unidades originales.
    - *Interpretación:* Bajo es mejor. Es más sensible a los valores atípicos (outliers) que el MAE.
    - *Contexto:* Predicción de clima, donde equivocarse por 10 grados es catastrófico comparado con equivocarse por 1 grado.
- R2 (Coeficiente de Determinación):
    - *Definición:* Proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes.
    - *Interpretación:* 1.0 es ajuste perfecto; 0 (o negativo) es un modelo que no predice mejor que el promedio.
    - *Contexto:* Reportes estadísticos y de investigación científica.

2) Razonamiento

1. Accuracy engañosa: En un problema donde el 99% son pacientes sanos y 1% enfermos, un modelo inútil que siempre diga "sano" obtendrá un 99% de *accuracy*, dando una falsa ilusión de éxito cuando en realidad falló en detectar al único enfermo.
2. Medicina (Falso Negativo): Si el evento es "enfermo", un falso negativo (decirle al paciente que está sano cuando tiene la enfermedad) es gravísimo porque no recibirá tratamiento y puede morir. Por ello, se debe priorizar la métrica de **Recall**.
3. RMSE vs MAE: El RMSE eleva los errores al cuadrado antes de promediarlos; por ende, un error de 10 unidades se convierte en 100 en la penalización. Esto es deseable en contextos donde los errores grandes son inaceptables o peligrosos (ej. predecir la trayectoria de un brazo robótico).

Ejercicio 4: Métricas en no supervisado: clustering y reducción

1) Investigación

En no supervisado, como no hay *ground truth* (etiquetas reales), medimos la estructura.

Clustering:

- Silhouette score : Mide qué tan similar es un objeto a su propio clúster (cohesión) comparado con otros clústeres (separación). Alto (cercano a 1) es excelente; negativo indica clasificación incorrecta. Falla en clústeres con formas no esféricas.
- Davies-Bouldin index : Calcula la relación entre la dispersión dentro de un clúster y la separación entre clústeres. Bajo (cercano a 0) indica un mejor clustering. Falla al depender mucho del concepto de centroide, limitando clústeres asimétricos.
- Calinski-Harabasz index : Relación entre la varianza de las sumas de cuadrados entre clústeres e intra-clústeres. Más alto es mejor. Límite: tiende a favorecer clústeres densos y convexos, ignorando formas complejas.

Reducción de dimensión:

- Varianza explicada (PCA) : Mide el porcentaje de información original que se retiene tras reducir las dimensiones. Alto (ej. 95%) es deseable. Límite: Solo captura relaciones lineales.
- Error de reconstrucción : Mide la diferencia entre los datos originales y los datos intentados reconstruir a partir de la versión reducida. Bajo es mejor. Límite: Sensible a outliers, puede requerir normalización estricta.

2) Razonamiento

1. Un buen modelo sin etiquetas: Significa que el modelo encontró una estructura matemática natural sólida en los datos: agrupó elementos muy similares entre sí y los separó claramente de elementos que son diferentes.
2. Métrica buena, inútil para el negocio: Imagina un clustering de clientes de un banco que, basado en sus nombres, agrupa perfectamente a todos los que empiezan con "A" en un lado y con "Z" en otro. Matemáticamente los clústeres son perfectos (buena métrica), pero para campañas de marketing es información inútil.
3. Validar con conocimiento previo: Si aplicas un clustering a pacientes médicos, puedes cruzar tus clústeres sin etiqueta con expedientes clínicos. Si notas que el Clúster 1 coincide mayoritariamente con fumadores (conocimiento previo), validas que el modelo encontró una estructura significativa.

Ejercicio 5: Diagnóstico de overfitting/underfitting

1) Investigación

- Curvas de aprendizaje (Learning curves): Son gráficos que muestran cómo evoluciona el desempeño del modelo (en el eje Y) conforme aumenta la cantidad de datos o el tiempo de entrenamiento (en el eje X), graficando tanto el set de entrenamiento como el de validación.
- Underfitting : Modelo demasiado simple (alto sesgo). Es como un estudiante que no estudió nada; falla tanto en las tareas (train) como en el examen (test).
- Overfitting : Modelo demasiado complejo (alta varianza). Es como un estudiante que memorizó las respuestas de la guía pero no entendió el concepto; saca 100 en la tarea (train) pero reprueba el examen (test).
- Buena generalización: El modelo aprendió los patrones fundamentales sin memorizar el ruido. Tiene buen desempeño en entrenamiento y ese desempeño se mantiene casi igual en datos nuevos.
- Rol del validation set: Sirve como un "examen de prueba". Permite evaluar el modelo durante el entrenamiento para ajustar los hiperparámetros y detener el proceso antes de que el modelo comience a memorizar (sobreajustarse).

2) Razonamiento

1. Train =0.98, Val =0.62, Test =0.60. **Diagnóstico: Overfitting.** Hay una brecha enorme entre el entrenamiento y la validación. El modelo tiene alta varianza; memorizó los datos de entrenamiento pero fracasa en generalizar datos nuevos.
2. Train =0.70, Val =0.69, Test =0.68. **Diagnóstico: Underfitting.** Las tres métricas están muy cerca, lo que indica baja varianza, pero el desempeño general es bajo (alto sesgo). El modelo es demasiado simple para capturar los patrones.
3. Train RMSE =5.0, Val RMSE =5.2, Test RMSE =5.1. **Diagnóstico: Buena generalización.** El error es consistente a través de los tres conjuntos de datos. Existe un buen equilibrio entre sesgo y varianza.
4. Train RMSE =1.0, Val RMSE =7.5, Test RMSE =7.8. **Diagnóstico: Overfitting.** El error en entrenamiento es casi perfecto (muy bajo), pero se dispara drásticamente en datos no vistos (alta varianza).

3) Extensión

1. Acciones para reducir overfitting:
    - *Modelo:* Reducir la complejidad de la hipótesis H (ej. podar un árbol de decisión o usar regularización).
    - *Datos:* Conseguir una cantidad mayor de datos de entrenamiento para que el modelo tenga más ejemplos y le sea más difícil memorizar el ruido.
1. Acciones para reducir underfitting:

    - Aumentar la complejidad del modelo (ej. pasar de una regresión lineal a una polinomial o a un ensamble).
    - Añadir mejores *features* (características) a los datos para darle al modelo más información de dónde aprender.
1. El test set y los hiperparámetros: Si usamos el set de prueba para afinar hiperparámetros, indirectamente estamos "filtrando" información de prueba hacia el modelo (Data Leakage). El set de prueba dejaría de ser un juez imparcial, arruinando nuestra medida de generalización en el mundo real.