



UNIVERSIDAD DE GUADALAJARA

Red Universitaria e Institución Benemérita de Jalisco

Reporte de proyecto final: Rendimiento Académico y Gamming



Introducción:

El presente reporte documenta el desarrollo de un sistema de predicción de rendimiento académico estudiantil mediante técnicas de aprendizaje automático. La pregunta central que motiva este proyecto es: ¿en qué medida los hábitos de vida de un estudiante en particular el tiempo dedicado al videojuego determinan su calificación académica?

Para responder esta pregunta se empleó el conjunto de datos Gaming vs Academic Performance (Kaggle), compuesto por aproximadamente 8,000 registros estudiantiles con variables como horas de juego, horas de estudio, horas de sueño, asistencia, nivel de estrés y puntaje de adicción, entre otras. La variable objetivo es la calificación académica (grades).

Se implementaron y compararon dos enfoques de regresión: una regresión lineal como modelo base (baseline) y una red neuronal densa construida con TensorFlow/Keras. Ambos modelos fueron entrenados sobre el mismo conjunto de datos preprocesado, permitiendo una comparación directa de su capacidad predictiva. El pipeline completo incluye limpieza de datos, codificación de variables categóricas, escalado con StandardScaler, división en conjuntos de entrenamiento, prueba y validación, entrenamiento, y predicción incluyendo predicción en paralelo mediante ThreadPoolExecutor.

Justificación de la selección de la data set:

Se seleccionó el data set Gaming vs Academic Performance (Kaggle) por tres razones concretas:

1. Su variable objetivo es continua (calificación numérica), lo que lo hace idóneo para regresión.
2. Sus ~8,000 registros ofrecen volumen suficiente para entrenar y validar modelos
3. Incluye variables conductuales y académicas que permiten explorar relaciones multivariadas relevantes al contexto educativo.

Los filtros/tags utilizados para su búsqueda fueron los siguientes:

- Data set de carácter científico
- Educativo
- Data analítica

Por estos motivos y los campos incluidos en la data set fue seleccionado.

Descripción de la Data set:

El data set utilizado es el siguiente: Gaming vs Academic Performance. Consta con alrededor de 8000 entradas.

La descripción de la data set en kaggle es la siguiente:

Este conjunto de datos explora cómo los hábitos de juego influyen en el rendimiento académico de los estudiantes.

A diferencia de conjuntos de datos simples, este modela patrones de comportamiento realistas: Jugar de forma moderada puede mejorar ligeramente el rendimiento cognitivo El exceso de juego afecta negativamente a las notas Las horas de estudio, el sueño y la asistencia influyen fuertemente en los resultados El ruido aleatorio simula la variabilidad en el mundo real. [Asper (2024)]

Características incluidas:

- ID Estudiante
- Edad
- Genero
- Horas de juego
- Horas de estudio
- Horas de sueño
- Genero del Videojuego
- Tiempo de reacción (rendimiento cognitivo)
- Niveles de estrés
- Nivel de adicción
- Asistencia
- Uso de dispositivos
- Calificaciones académicas (variable objetivo)

Casos de uso: Predecir el rendimiento del alumnado (modelos de regresión) Análisis de datos conductuales Visualización de datos (EDA) Proyectos de aprendizaje automático

Descripción Procesamiento de Datos:

El procesamiento de los datos se realizó en un Jupyter Notebook utilizando principalmente las bibliotecas pandas, numpy y scikit-learn. El flujo utilizado para la limpieza de datos se puede dividir en las siguientes etapas:

1. Carga del dataset

Se cargó el archivo CSV original (Gaming_Academic_Performance.csv) utilizando `student_id` como índice, resultando en 7,995 registros con 13 columnas.

2. Separación de variables por tipo

Se identificaron dos grupos de columnas:

- Numéricas: `age`, `gaming_hours`, `study_hours`, `sleep_hours`, `attendance`, `social_activity`, `device_usage`, `reaction_time_ms`, `addiction_score`, `grades`
- Categóricas: `gender`, `gaming_genre`, `stress_level`

3. Tratamiento de valores faltantes

- Variables numéricas: imputación con la mediana de cada columna
- Variables categóricas: imputación con la moda de cada columna

4. Codificación de variables categóricas

Las tres variables categóricas se transformaron a valores enteros mediante `LabelEncoder` de `scikit-learn`, convirtiendo etiquetas como "Male" / "Female" o "Low" / "Medium" / "High" a representaciones numéricas (0 a n).

5. Separación de conjuntos

Validación: los últimos 5 registros del dataset se reservaron manualmente como conjunto de validación final

Del resto (7,990 registros): 80% entrenamiento y 20% prueba, usando `train_test_split` con `random_state=42` para reproducibilidad

6. Escalado de variables

Se aplicó `StandardScaler` exclusivamente a las variables numéricas (excluyendo la variable objetivo "grades" y las categóricas, que ya son enteros discretos). El escalador se ajustó

únicamente con el conjunto de entrenamiento y se aplicó —sin reajustar— a los conjuntos de prueba y validación, evitando fuga de datos (data leakage).

7. Exportación

Los seis conjuntos resultantes (X_train, X_test, X_val, y_train, y_test, y_val) se exportaron como archivos CSV independientes en data/Data_Limpia_y_Separada/ para su uso posterior en el entrenamiento de modelos.

Descripción de los modelos Seleccionados:

Regresión Lineal

Se selecciono este modelo ya que es la referencia base con la cual se busca hacer predicciones y/o relaciones entre variables. La implementación fue realizada con LinearRegression de scikit-learn. Esta asume la relación lineal entre las 12 variables de entrada y la calificación académica. No requiere hiperparámetros manuales; el ajuste se realiza mediante mínimos cuadrados ordinarios.

<i>Parámetro</i>	<i>Valor</i>
<i>Implementación</i>	sklearn.linear_model.LinearRegression
<i>Hiperparámetros</i>	Ninguno (valores por defecto)
<i>Variables de entrada</i>	12
<i>Variable objetivo</i>	grades (continua)

Resultados:

	<i>MSE</i>	<i>MAE</i>	<i>R²</i>	<i>Huber</i>
<i>Test</i>	48.6623	5.5177	0.9052	5.036
<i>Validacion</i>	58.2530	6.5582	0.8931	6.137

Red Neuronal

La Red neuronal secuencial fue construida con TensorFlow/Keras. Diseñada para regresión sobre el mismo conjunto de datos. Seleccionada para ver como modelos más complejos interactúan con este conjunto de datos y medir su desempeño contra los modelos más simples

<i>Parámetro</i>	<i>Valor</i>
<i>Implementación</i>	tf.keras.Sequential
<i>Capas</i>	Input(12) → Dense(128, linear) → Dense(1)
<i>Optimizador</i>	AdamW
<i>Función de pérdida</i>	Huber
<i>Épocas</i>	50
<i>Batch Size</i>	32
<i>Variables de entrada</i>	12

Resultados:

	MSE	<i>MAE</i>	R^2	<i>Huber</i>
<i>Test</i>	48.6623	5.5647	0.9042	5.083
<i>Validacion</i>	58.2530	6.6894	0.8944	6.1894

Comparación entre modelos:

<i>Test</i>	MSE	<i>MAE</i>	R^2	<i>Huber</i>
<i>RL</i>	48.6623	5.5177	0.9052	5.036
<i>NN</i>	49.2541	5.5647	0.9042	5.083

<i>Validacion</i>	MSE	<i>MAE</i>	R^2	<i>Huber</i>
<i>RL</i>	58.2530	6.5582	0.8931	6.137
<i>NN</i>	60.5284	6.6894	0.8944	6.1894

Conclusiones:

El proyecto demostró que es posible predecir el rendimiento académico estudiantil con buen grado de precisión a partir de las variables de la data set (conductuales y de hábitos de vida). Ambos modelos implementados alcanzaron buenos resultados, con coeficientes de determinación superiores a 0.89 en todos los conjuntos evaluados.

Una observación relevante es que la regresión lineal obtuvo resultados similares y ligeramente mejores que la red neuronal (MAE de 5.51 vs 5.56 en test), lo que da a entender que la relación entre las variables de entrada y la calificación académica es lineal. Esto valida el uso del modelo de regresión lineal como base sólida para este tipo de problemas.

El Flujo de trabajo completo desde la limpieza de datos, codificación, escalado, entrenamiento y predicción en paralelo es funcional, reproducible y escalable a nuevos registros de estudiantes.

Recomendaciones:

- Ampliar el conjunto de validación más allá de 5 registros para obtener métricas de validación estadísticamente representativas
- Incorporar análisis de importancia de variables para identificar qué factores (horas de estudio, sueño, asistencia) tienen mayor peso predictivo

Algunos trabajos a futuro pudieran ser:

- Explorar modelos de mayor complejidad (XGBoost, Random Forest) antes de aumentar la profundidad de la red neuronal, dado que el problema parece ser esencialmente lineal
- Adaptar el modelo con datos reales del SIIAU (calificaciones, asistencia, carga académica) para predicción temprana de alumnos en riesgo de reprobación
- Extender el análisis a nivel carrera/centro universitario para identificar patrones por área de conocimiento (exactas, sociales, salud)

Bibliografía:

Asper (2024). Gaming vs Academic Performance [Dataset]. Kaggle.

<https://www.kaggle.com/datasets/aiexplorer77/gaming-vs-academic-performance>

Recuperado el 13 de mayo de 2026.

Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., ... Zheng, X. (2015). TensorFlow: Large-scale machine learning on heterogeneous systems [Software]. Google Brain. <https://www.tensorflow.org>

Recuperado el 13 de mayo de 2026.

Chollet, F., & colaboradores. (2015). Keras [Software]. <https://keras.io> Recuperado el 13 de mayo de 2026.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

<https://jmlr.org/papers/v12/pedregosa11a.html> Recuperado el 13 de mayo de 2026.